


Briser les silos de données pour une vision à 360° du cancer.

Présentation de la Plateforme d'Intelligence Oncologique Unifiée

La complexité du cancer exige une analyse qui transcende les sources de données traditionnelles. Les informations cliniques, épidémiologiques et diagnostiques sont souvent isolées, limitant notre compréhension globale et notre capacité à prendre des décisions éclairées.

Ce projet répond à ce défi en créant un entrepôt de données multi-sources, conçu pour unifier des informations hétérogènes et révéler des connexions inédites entre les profils de patients, les facteurs de risque et les marqueurs biologiques.




L'architecture en Constellation : le moteur de notre analyse croisée.

Pour répondre à la complexité de nos sources, nous avons implémenté un schéma en Constellation (Galaxy), une architecture multidimensionnelle avancée.

Contrairement à un schéma en étoile simple, cette structure utilise plusieurs tables de faits (une pour chaque source) qui partagent des dimensions communes (comme `dim\_date`).



Avantages clés :

- **Modularité** : Chaque domaine d'analyse (sein, poumon, diagnostic) reste logiquement isolé.
- **Cohérence** : Les dimensions partagées garantissent des comparaisons fiables entre les datasets.
- **Performance** : Optimisé pour les requêtes analytiques complexes.




Analyse Clinique (Sein) : La survie à long terme, une réalité pour la majorité des patientes.

L'analyse de 4 026 dossiers cliniques révèle une distribution de la survie encourageante. Un pic de survie se situe entre 60 et 80 mois, témoignant de l'efficacité des protocoles de traitement. La "longue traîne" de la distribution, avec des survies dépassant 100 mois, ouvre la voie à des études sur les facteurs de succès exceptionnels. La majorité des patientes des patientes sont diagnostiquées à des stades intermédiaires (IIA : 32,4%, IIB : 28,1%), soulignant l'importance d'un dépistage encore plus précoce.



La corrélation entre la taille de la tumeur et le stade clinique valide la qualité de nos données.




Notre système confirme une corrélation clinique fondamentale : la taille moyenne de la tumeur augmente de manière quasi-exponentielle avec la progression du stade T (T-Stage). Cette cohérence parfaite entre la mesure physique (mm) et la nomenclature clinique (T1 à T4) est un test réussi de la robustesse et de la fiabilité des données intégrées dans notre entrepôt.

Analyse Épidémiologique (Poumon) : Un 'profil symptomatique' clair distingue les patients positifs.

L'analyse des données d'enquête révèle des signatures symptomatiques distinctes. Le profil des patients positifs au cancer du poumon (en jaune) est nettement plus prononcé que celui des patients sains.

Le 'trident' symptomatique le plus discriminant est formé par la **fatigue**, la **toux** ('coughing') et les **douleurs thoraciques** ('chest_pain').

Cette visualisation permet à un praticien d'évaluer le risque clinique d'un patient par simple comparaison géométrique avec le profil de référence.




Le tabagisme et l'alcool sont les facteurs de risque les plus fortement corrélés à un diagnostic positif.


La matrice de corrélation quantifie les liens entre les facteurs de risque, les symptômes et le diagnostic de cancer du poumon.

Comme attendu, le **tabagisme** (smoking) présente la plus forte corrélation avec le diagnostic (lung_cancer[®]) avec un coefficient de **0.70**.

La consommation d'alcool (alcohol_consuming) est également un facteur significatif. De plus, un 'score de sévérité des symptômes' (symptom_severity) composite que nous avons calculé est fortement corrélé au diagnostic (0.52).



Analyse Diagnostique (Wisconsin) : Les mesures morphologiques séparent quasi-parfaitement les tumeurs malignes et bénignes.




L'Analyse en Composantes Principales (ACP) a été appliquée à 30 mesures morphologiques de noyaux cellulaires. Le résultat est une séparation visuelle presque parfaite entre les tumeurs bénignes (en orange) et malignes (en vert). Les deux premières composantes principales (PC1 et PC2) expliquent à elles seules plus de 63% de la variance totale (44.32% + 18.82%).

Cette analyse valide l'immense potentiel des données d'imagerie pour créer des outils d'aide au diagnostic extrêmement fiables.

Le rayon, la texture et la concavité sont des discriminateurs clés au niveau niveau cellulaire.


Les tumeurs malignes présentent systématiquement des valeurs médianes plus élevées et une dispersion (variance) plus importante sur les mesures clés comme le rayon moyen (radius_mean), l'aire (area_mean), la texture (texture_mean) et la concavité (concavity_mean). Cette variabilité accrue est un marqueur connu de l'anarchie cellulaire caractéristique des tissus cancéreux.

Ces visualisations permettent de définir des seuils d'alerte automatiques pour les systèmes de diagnostic assisté par ordinateur.




La Synthèse : L'entrepôt unifié révèle des différences démographiques et de prévalence entre les pathologies.

La véritable puissance de notre architecture en Constellation réside dans sa capacité à croiser des populations hétérogènes.



Démographie comparée : La population atteinte du cancer du poumon est concentrée sur les tranches d'âge 50-70 ans, tandis que le cancer du sein touche une population plus jeune et plus étendue.




Prévalence et sévérité : Le taux de positivité dans l'enquête sur le cancer du poumon (87,4%) est très élevé, tandis que le taux de mortalité observé dans la cohorte clinique du sein est de 15,3%.

Au-delà de l'analyse : un outil d'aide à la décision interactif avec Power BI.

Pour transformer nos analyses en un outil de pilotage dynamique, nous avons connecté notre entrepôt de données PostgreSQL à une solution de Business Intelligence interactive sur Power BI.

Le schéma en Constellation a été importé nativement, préservant toutes les relations complexes entre les données.

Les praticiens peuvent désormais explorer les données de manière fluide, en appliquant des filtres croisés qui impactent simultanément les trois sources de données.




L'exploration dynamique permet d'isoler les combinaisons de facteurs de risque les plus critiques.

La solution interactive va au-delà des graphiques standards. Des outils comme l'arborescence de décomposition (Decomposition Tree) permettent d'effectuer un 'drill-down' intelligent sur des indicateurs clés comme le taux de survie.

L'utilisateur peut explorer dynamiquement comment le pronostic est influencé par une combinaison de facteurs (Stade, Âge, Race), identifiant ainsi les sous-populations les plus à risque.

Toutes les mesures clés (Taux de Survie, Score de Risque Moyen) ont été réimplémentées en langage DAX pour garantir des calculs en temps réel.



```
[Survival_Rate] =  
DIVIDE(  
    CALCULATE(  
        COUNT('public fact_breast_clinical'[id]),  
        FILTER(  
            'public fact_breast_clinical',  
            'public fact_breast_clinical'[outcome_id] = 1  
        )  
    ),  
    COUNT('public fact_breast_clinical'[id]),  
    0  
)
```


Recommandations stratégiques et perspectives : vers une médecine de précision pilotée par les données.

Recommandations issues de l'analyse :

- 1. Renforcer le dépistage précoce (Stade T1) : Nos données confirment le lien direct entre un diagnostic précoce, une taille tumorale réduite et un meilleur pronostic.
- 2. Digitaliser le diagnostic : L'extrême fiabilité de la séparation Bénin/Malin via les mesures morphologiques justifie l'intégration de ces algorithmes en aide au diagnostic.

Perspectives d'évolution :

- Machine Learning : Développer des modèles prédictifs de risque de rechute directement connectés au DWH.
- Analyse Génomique : Étendre la constellation avec des données génomiques pour croiser la morphologie cellulaire et les marqueurs génétiques.
- Interopérabilité (FHIR) : Adapter le schéma pour supporter les standards d'échange de données de santé et s'intégrer à d'autres systèmes hospitaliers.

